

Projeto 1 - CB

Análise Exploratória de Dados (EDA)

Educacional – Insper Data

Ciclo Básico – 2026.2

Entrega: apresentação de 5 minutos até **10/09**

Apresentação

Neste primeiro projeto do Ciclo Básico, cada dupla receberá uma base de dados real e uma pergunta para investigar, colocando em prática o que foi visto nas Aulas 1 a 3: instalação e uso de Git/GitHub, limpeza e manipulação de dados e análise exploratória com gráficos. Como regressão linear ainda não foi vista, **toda a investigação deve ser respondida apenas com Análise Exploratória de Dados (EDA)**: estatísticas descritivas, comparações entre grupos, correlações e boas visualizações. Não se ajusta nenhum modelo estatístico formal, uma EDA bem feita e bem argumentada é, por si só, a resposta completa à pergunta-guia.

Tão importante quanto a técnica é a forma como a história é contada. Pensem na apresentação como um **storytelling**: comecem contextualizando o problema, pensando no por que ele é relevante, o que motiva essa investigação e só então cheguem à pergunta-guia, de forma natural. Evitem jogar a pergunta na plateia sem antes construir o cenário que a justifica.

As bases ainda não serão reveladas por dupla. Assim que todas as duplas forem formadas e informadas a nós, cada uma receberá a sua base e a pergunta correspondente. Até lá, este documento serve como guia geral para que todos saibam o que esperar e possam já revisar os materiais de apoio.

Não se esqueçam de criar um repositório no GitHub para o projeto. Ele deve conter o(s) notebook(s) com o código da análise, os gráficos gerados, um `README.md` explicando o problema, os dados e as principais conclusões, e (se o tamanho do arquivo permitir) a base de dados utilizada ou instruções claras de como obtê-la. (Se precisarem de ajuda em como adicionar um colaborador (no caso a sua dupla) mandem mensagem!

Formato geral do trabalho

Independentemente da base recebida, espera-se que cada dupla percorra as seguintes etapas:

- **Contexto e motivação:** antes de qualquer coisa, montem o cenário – por que esse problema importa, para quem ele importa. É esse contexto que leva a plateia até a pergunta-guia.
- **Entendimento do problema:** reformular a pergunta-guia com as próprias palavras.
- **Limpeza dos dados:** tratar valores ausentes, duplicados e inconsistentes; justificar as decisões tomadas. Pegar os valores relevantes para a análise do problema e resolução da pergunta.
- **Análise exploratória (EDA):** esta é a etapa central e deve responder sozinha à pergunta-guia, estatísticas descritivas, comparações entre grupos/categorias, correlações e gráficos (dispersão, boxplot, histograma etc.) que sustentem a conclusão.
- **Conclusão e limitações:** fechem com uma conclusão clara, mas reservem tempo de verdade para as limitações, ou seja, o que os dados não permitem afirmar, possíveis vieses, variáveis que faltam e o cuidado entre correlação e causalidade. Essa parte deve ter tanto destaque quanto a resposta em si.

Tema 1 – Airbnb: características do imóvel e valor da diária

O preço de uma diária no Airbnb depende de uma combinação de fatores relacionados à própria acomodação. Investigar quais características pesam mais nessa formação de preço ajuda a entender a lógica (nem sempre óbvia) por trás da precificação dinâmica de plataformas de hospedagem.

Base: [Airbnb Dataset \(Kaggle – ashishjangra27\)](#)

Pergunta-guia: Quais características da acomodação (tipo de quarto, número de banheiros ou camas) têm maior impacto no valor da diária?

Para explorar essa pergunta, considerem também:

- As colunas disponíveis podem variar conforme a versão da base – confirmam o que existe (tipo de quarto, número de avaliações, disponibilidade, mínimo de noites e, se presentes, número de banheiros/camas/quartos) antes de decidir quais usar.
- Existe diferença clara de preço entre os diferentes tipos de quarto (inteiro, privado, compartilhado)?
- As variáveis numéricas disponíveis (ex.: número de banheiros, camas ou capacidade de hóspedes) têm relação aproximadamente linear com o preço, ou o efeito parece saturar a partir de certo ponto?
- A localização (bairro ou região) interfere na relação entre as características do imóvel e o preço?
- Dentre as variáveis disponíveis, qual delas mostra a relação mais clara com o preço nos gráficos exploratórios (por exemplo, boxplots por tipo de quarto ou dispersão contra número de banheiros/camas)?

Tema 2 – E-commerce: atraso na entrega e avaliação do cliente

Marketplaces como o Olist dependem fortemente da satisfação do cliente para manter vendedores ativos e conquistar novos compradores. A entrega é um dos pontos de maior atrito na experiência de compra online, e entender seu efeito sobre a avaliação deixada pelo cliente é essencial para pensar em melhorias operacionais.

Base: [Brazilian E-Commerce Public Dataset by Olist \(Kaggle\)](#)

Pergunta-guia: O atraso no tempo de entrega impacta diretamente a nota de avaliação deixada pelo cliente?

Para explorar essa pergunta, considerem também:

- Como definir “atraso”? Uma opção é a diferença entre a data de entrega estimada (`order_estimated_delivery_date`) e a data de entrega efetiva (`order_delivered_customer_date`).
- A relação entre atraso e nota parece linear, ou existe um “limite de tolerância” a partir do qual a nota despenca de forma mais abrupta?
- O impacto do atraso é semelhante entre diferentes categorias de produto, ou algumas categorias são mais sensíveis a atrasos que outras?

- Vale cruzar as tabelas de pedidos (`orders`) e avaliações (`order_reviews`) – cuidado com pedidos sem avaliação ou sem data de entrega registrada.

Tema 3 – Spotify: características de áudio entre gêneros musicais

Plataformas de streaming como o Spotify traduzem qualidades musicais que antes eram subjetivas, por exemplo: o quanto uma música é dançante, energética ou acústica, tudo isso em números. Comparar essas características entre gêneros distintos ajuda a entender o que faz cada gênero soar do jeito que soa, e é também a base de sistemas de recomendação musical.

Base: [Spotify Tracks Dataset \(Kaggle – maharshipandya\)](#)

Pergunta-guia: Como as características de áudio diferem entre dois gêneros musicais distintos (ex.: Rock vs. Reggaeton) usando gráficos de densidade?

Para explorar essa pergunta, considerem também:

- A base tem dezenas de gêneros na coluna `track_genre`, filtrem para os dois gêneros escolhidos (podem manter Rock vs. Reggaeton ou escolher outro par sonoramente distinto, desde que justifiquem a escolha).
- Entre as características de áudio disponíveis (`danceability`, `energy`, `valence`, `acousticness`, `tempo`, `loudness`, `speechiness` etc.), quais mostram distribuições mais separadas entre os dois gêneros nos gráficos de densidade (KDE)?
- Existe alguma característica cuja distribuição praticamente se sobrepõe entre os dois gêneros, ou seja, que não ajuda a diferenciá-los?
- A popularidade das faixas varia entre os dois gêneros, e isso parece se relacionar com as características de áudio observadas?

Material de apoio

O notebook abaixo mostra um fluxo completo de análise (limpeza, EDA e, ao final, uma regressão linear). Como ainda não vimos regressão, foquem apenas nas partes de limpeza e análise exploratória como referência de raciocínio e organização de código – ele não é a base do projeto de vocês, é só um exemplo:

- [Netflix Movies & TV Shows – Linear Regression \(Kaggle\)](#)

Formato da apresentação (5 minutos)

A apresentação é curta, então o foco deve ser em comunicar com clareza – não em mostrar todo o código. Sugestão de estrutura:

1. **Contexto e pergunta** (até 1,5 min): esta é a parte do storytelling – contem a história que leva até a pergunta-guia antes de enunciá-la. Não comecem direto pela pergunta.
2. **Limpeza dos dados** (até 0,5 min): principais problemas encontrados e como foram tratados, de forma rápida.
3. **Análise exploratória e resposta** (até 2 min): os gráficos e comparações que melhor respondem à pergunta – este é o coração da apresentação.
4. **Conclusão e limitações** (até 1 min): fechem com destaque real para as limitações – o que a EDA não permite provar, possíveis vieses e cuidados de interpretação. Essa parte merece o mesmo capricho que a resposta em si, não uma frase solta no final.

Entrega

- **Prazo:** apresentação até **10/09**, no formato de seminário interno (Slides feitos a partir do template do data).
- **Duração:** 5 minutos por dupla. + 3 min de perguntas
- **Repositório GitHub:** obrigatório, com notebook(s), gráficos, README.md e instruções para reprodução da análise.
- Enviem o link do repositório à coordenação até uma hora antes da apresentação.

Observação: formem as duplas e informem a coordenação o quanto antes, visto a base de cada dupla só será revelada depois de todas as duplas confirmadas. Observação 2 : Cuidado para não entenderem o que a IA está fazendo! Lembrem-se de não deixar a IA pensar por você durante o desenvolvimento.